

6

教育評価

●ポイント

教育においては、その効果を測定し評価することが求められる。近年は特にアカウンタビリティ（説明責任）の観点からも教育評価はきわめて重要になっている。また、適切な教育活動を計画・展開するに当たっても、児童・生徒の側に備わっている状態（レディネスなど）を測定することが必要となる。ここでは、計量心理学及び統計学的な観点を含みつつ、学力テストから知能検査まで、幅広く基礎的事項とその応用について概観する。

頻出事項は、評価の分類であり、相対評価と絶対評価、そして形成的評価の内容についてはしっかり理解しておきたい。また、評価の歪みに関わる現象として、ハロー効果やビッグマリオン効果も出題が多い。そして、知能検査については、その種類を体系的に整理し、それぞれの特徴を理解しておく必要がある。

1 測定と評価

(1) 測定とは

心理学はこれまで、自然科学の方法論を取り入れて進歩してきた。いうまでもなく、心理学の主な研究対象は人間である。とかく主観的なアプローチになりがちであるからこそ、観察した結果を客観的に表現しようという試みがなされてきた。

数による記述にはものさし（尺度）が必要である。身長、体重などの事物・現象を測る場合（物理的測定）や、脈拍や血圧など生理的な数値を測る場合を考えると、体重計、体温計や血圧計などの道具や表示の単位も様々である。しかし、一定のルールに従って対象に尺度を当てはめて、65キログラムや36.5度といった数字を用いて結果を表す点では共通している。このように、ある対象に数値を付与することを**測定**という。また、数値の集合を**尺度**という。

一方、心理的な対象の場合（心理的測定）についてはどうであろうか。例えば、知能、学力、性格など、対象は直接目に見えず、身長や体重のように直接的に測れないのである。こうした心理学的な対象を測定するには数々の工夫が必要であった。

1900～1920年は測定万能の時代といわれ、知能や学力などの心理的測定が積極的に開発され試みられた。学校で頻繁に用いられる「テスト」は、こうして発達してきた測定方法の一つなのである。

(2) 評価とは

教育測定万能の時代を過ぎると、教育の改善、進歩に測定結果を役立てることが大切であると主張され始める。そして、教育測定にかわり、教育評価という言葉が登場する。**評価**とは、「価値づけ、値ぶみをする事」である。

教育評価とは、指導の結果が目的、目標に達しているかを判断することである。広義には、評価には測定を含んでいる。例えば、体重計で「63キログラム」と読み取るのは測定である。一方、「63キログラムなら普通くらいの体重だ」あるいは「比較的多めだ」という判断が加わると評価である。同じ測定結果でも、視点次第で異なった評価に至ることもある。測るだけではなく、その結果の意味を考えて、教育を改善することこそ大事である。

教育評価の領域には、知能・学力、性格・適性、身体・健康、学校の評価、教師の評価などがある。

(3) 評価の機能

評価には次のような機能がある。

- ① 目標への到達度や学習の進み具合を診断する。
- ② 教師が指導を振り返って反省し、以後の指導の改善に役立てる。
- ③ 児童生徒が自己評価し、確認するのを助け学習を動機づける。
- ④ 学校の学力水準を明らかにし、父母や社会の批判に応えその協力を得る。

教育評価は①～③の機能にみられるように、学習と指導を改善するための手続きである。子どもの理解度を決めつけるための道具ではない。教師は普段のテストや通知票の意味などを正しくとらえ直す必要がある。教育評価は学習指導過程の要といわれるほど大切な意味をもっているのである。

また④の機能は、最近アメリカで「アカウンタビリティ」（教育成果の説明責任）とよばれ、重視されている。納税者にはその支出に見合うだけの成果を学校があげているかを知る権利がある、という考え方が広まっているのである。ただ、この目的のための評価は、教育を歪めるおそれがあるため、注意深く用いるべきである。

2 テストの備えるべき条件

教育評価に用いる測定道具としてのテストには、備えるべき条件がいくつかある。一般には、**信頼性**と**妥当性**の2つが最低限重視され、さらに実用性などが条件に加えられる。

(1) 信頼性

測定誤差が小さく、何回行っても同じ結果が得られることを信頼性が高いという。つまり、検査によって得られた測定値の正確性や安定性を**信頼性**という。例えば、体温計を使って2回続けて体温を測るとする。1回目は36.7度であったが、念のためにもう一度測ると、今度は何と38.4度に上がっていた。このような体温計は、信頼性がないといえるだろう。心理テストの信頼性という概念には、テスト結果の安定性や恒常性、テスト内部の均質性などを含んでいる。

あるテストがどの程度の信頼性をもっているかは、信頼性係数で示される。信頼性係数は、次のような方法で求められる。

再検査法…同じ生徒を対象にし、期間をおいて同じテストを2回繰り返して、2回のテスト得点間の相関係数を求める方法である。ただし、1回実施することによって、2回目以降の得点に変化が生じるような性質の内容である場合には他の方法で信頼性係数を求める必要がある。

平行(並行)検査法…原検査と同じ領域を網羅した等価的なテストを作り、両者を実施して相関係数を求める方法である。特に、既成のテストがあり、その短縮版を新しいテストとして作成する場合にはこの方法を用いることができる。ただし、これまで測定されなかった新しい領域のテストを開発する際には平行検査法を使うことはできない。

折半法…一つのテストは通常、数多くの問題項目から成り立っているが、平行な2つのテストに分割し、両者の相関係数を推定する方法である。例えば20題で各5点、計100点満点のテストがあるとする。20題を奇数番目の10題と偶数番目の10題というように二分し、50点満点のテスト2つとして別々に集計する。すると、1人の生徒につき2つのテスト得点が得られる。これら2つのテスト得点間の相関係数を求める方法である。また、すべての組み合わせを考慮した信頼性係数の推定値として、クロンバックの α 係数とよばれる値が広く使われている。

(2) 妥当性

テストは信頼性の高さだけで十分というわけではない。例えば体重を測るときに、信頼性の高い身長計を用意しても、体重の測定という目的にはそぐわない。体重計という適切な道具を用い、かつ数値を正しく読み取って初めて正しい測定となる。このように、測定しようと意図したものを、正しくとらえている程度を**妥当性**という。ただし、妥当性の高さは信頼性の高さを前提としており、信頼性が低くて妥当性が高いということはありません。なぜなら、信頼性が低いというのは、究極的にはサイコロの目のように数値がランダムに割り振られる(誤差が大きい)状態であり、何も測定していないのと同じだからである。妥当性は、さらにいくつかに分けて考えられる。

① 内容的妥当性

テスト問題を作成する際に、指導目標となった範囲から偏りなく問題を選んできたか、が問題となる。

また算数の文章題では、単純な計算問題などよりも誤答が多くなる。誤答の理由を調べてみると、文章が理解できないためにつまずく生徒が少なくない。このようなテスト問題は、算数の学力ではなく、文章の理解力を測定しているのではないか。こうした観点から妥当性を検討するとき、内容的妥当性を問題にしているのである。

② 基準関連妥当性

テストの結果と他の何らかの基準(外部基準)との相関を検討する。進学適性と大学の入学後の成績との相関などは、予測的妥当性といわれる。また、新しいテストを作成した場合に、一般的に有用さを認められている既存のテストとの相関を調べることがある。そのテストが従来使われてきたものと同じ目標を測っているのなら、相関は高くなる。

③ 構成的妥当性

調べようとしているものの本質的な概念とその概念を構成している下位尺度の内容が矛盾なく関連するかということを見るものを構成的妥当性という。例えば、知能テストは空間知覚(下位テスト1)、推理力(下位テスト2)、記憶(下位テスト3)など多数の下位テストから成り立っている。こうした下位テスト間の相関をみる。相関が高過ぎる場合、同じ知的側面を重複して測っているのではないのかという疑問が出てくる。一方、低過ぎると、果たしてこれが知能の1因子だと考えるべきなのか疑問となる。このように、各下位テスト間の相関関係を分析していくのである。

(3) その他の条件

採点基準が明確で、誰が採点しても同じ結果が得られるテストは客観性があるテストといわれる。また、能力の高い人の正答率と、低い人の正答率との間に明確な差の出るテストは、識別性の高いテストだといわれる。入学試験では、受験生が皆同じ点数を取ってしまうと、合否判定の役には立たない。こうしたテストでは、識別性が重要なのである。

以上の他、テストには実用性も求められる。具体的には、次のような条件を挙げることができよう。

- ① 特別な器具などの準備が不要で実施が容易であること。
- ② 採点が容易であること。
- ③ 標準テストの場合はマニュアルが整っていること。
- ④ かけた時間や労力に対して得られる情報量が多いこと。
- ⑤ 安上がりを実施、採点できること。つまり経済性を考慮すること。

3 評価の種類

(1) 比較の基準による分類

評価は様々な種類に区別できる。まず、何を基準にして評価するかによって、次の3つに分けられる。

① 相対評価

集団内での相対的な位置を示し、評価することを**相対評価**という。つまり、集団内の他の人たちと比較して、個人の位置を示すものである。受験者を得点順に並べて、上から一定の数だけ合格させる入学試験は、その代表例である。また、通知票で広く用いられてきた「5段階評定」も、学級や学年内での位置を、5から1の数字で示す方法である。

② 絶対評価

他の人たちの成績には無関係に、あらかじめ定められた目標や基準を、個人が達成しているかどうかで評価することを**絶対評価**という。例えば、運転免許証を取得するための試験などは、これに当たる。絶対的な到達基準があり、それを満たせば何人でも合格者が出る。ただし、その基準をどのように設定するか、またどの程度基準を満たしているかという判断には難しい面もあり、今後の研究課題といえよう。なお、**到達度評価**も絶対評価とほぼ同じ意味で用いられる。

③ 個人内評価

特定の個人がどんな特徴をもっているのか、また以前より進歩したのかどうか、という観点から評価することを**個人内評価**という。

算数のテストで同じ70点を取ったとしても、他の教科で満点ばかり取っている子にとっては、不満な結果に違いない。また、前回60点しか取れなかった生徒は70点ならよくできたと感じるだろうし、逆に前回90点取った生徒はだめだったかもしれない。このように、テストの得点が誰にとっても共通の意味をもつとはいえないのである。

(2) 実施の時期による分類

時間を費やせばどの子にもどんな内容でも理解させることができるというキャロルの発想をもとに**完全習得学習**(マスタリー・ラーニング)を提唱したアメリカの**ブルーム**らは、その実現に向けて、評価を**診断的評価**、**形成的評価**、**総括的評価**という3タイプに分けて考えた。診断⇒形成⇒総括

① 診断的評価

指導計画を立てる際に、事前に児童生徒の**レディネス**の度合いを把握するために用いる評価である。例えば、「2年生になれば、もう当然このような内容ができるだろう」といった思い込みで指導すると失敗することもある。まず生徒の実態を的確に把握することであり、単元に入る前に診断的な評価をすることが望まれる。

② 形成的評価

学習活動の途中で、児童生徒の実態をとらえ、それに基づいて指導計画を変えたり、補充的指導をしたりする評価の在り方をいう。ある事項についての解説をした教師が、児童生徒の様子から「私の今の説明は、どうも理解しづらかったようだな。」と感ずることがあるだろう。このとき、教師は直ちに説明を繰り返す、別の例を挙げるなどして対処する。こうした例からもわかるとおり、理解の程度を評価する方法は、テスト法だけではない。むしろ、日常的に児童生徒を観察することによって、教師は多くの情報を得ている。

形成的評価には、目標への到達状況をつかみ、以後の学習活動を調整する(完全習得のための今後の努力、時間をみてとる)という意味があり、評価結果を指導にフィードバックするというように表現されることもある。したがって、形成的評価の目的は、授業、学習、カリキュラム等の改善にあるといえる。

③ 総括的評価

学期末試験や学年末試験のように、一連の学習活動の終わりに、成果を確かめる目的で行われる評価のことである。

ブルームの分類は、実施される時期によると考えると覚えやすい。つまり、最初に診断、次に形成、最後に総括という具合である。中でもブルームは特に形成的評価を重要視していた。また、3つの評価ともに、完全習得学習という目標に照らして、絶対評価で行われることが前提である。

(3) 教育評価の将来

現代の教育評価に対しては、次のような批判がなされている。

- ① 記憶、理解を中心にした狭い領域だけが測定されがちである。
- ② 総括的である。
- ③ 評価が教育を歪めている。

入試にみられるように、評価の現実が学校教育の在り方を左右しているのである。そこで、今後の在り方として、以下のような方向が求められる。

- ① 減点主義から加点点主義の発想へ。
- ② ペーパーテストから、作品、観察、実演などの他、多様な方法の利用へ。
- ③ 記憶重視から創造性や問題意識を含めて問う方向へ。
- ④ 教師のみによる評価から、児童生徒による自己評価なども含めた総括的な方法へ。

●ポートフォリオ評価

ポートフォリオとは「紙ばさみ」「書類入れ」という意味である。児童・生徒が各自の学習活動で生み出した様々な作品やレポートなどを個人ごとに蓄積し、進歩のプロセスを分析するのがポートフォリオ評価である。これは数値化が困難な質的側面を評価する方法として有効であり、個人内評価あるいは自己評価の道具として、総合的な学習の時間などでの活用が期待されている。

●パフォーマンス評価

児童・生徒に知識や技能を表現させたり応用させたりするような課題を行わせ、それを評価者が観察し、習得した知識・技能を使いこなす能力を評価すること。

●ルーブリック評価

成功の度合いを示す数レベル程度の尺度と、それぞれのレベルに対応するパフォーマンスの特徴を示した記述語(評価規準)からなる評価基準表をもとに行う評価である。ディスカッションやグループワークなどで学習する「技能」、「表現力」、「思考力」、「判断力」といった実演でのパフォーマンスや、「興味・関心」、「意欲」、「態度」といった課題への取り組み姿勢を明確に評価できる点に特徴がある。

4 適正な評価を阻害するもの

評価を行う際、何らかの要因によって適正な評価が妨げられることがある。ここでは、そのような現象について説明する。

(1) ハロー効果(光背効果、後光効果)

ハロー(halo)とは、聖像などの背後にみられる光の輪(後光)のことである。後光が差すというときの後光と考えてもいい。そして背後に光の輪を背負った聖像は、神々しくみえるものである。つまり、測定すべき特性そのものではなく、観察対象に対するよい(悪い)印象によって、ほかの諸側面についてもよい(悪い)と判断しがちである。このように、測定結果が影響されることをハロー効果という。ハロー効果は、他にも光背効果、後光効果などともよばれる。例えば、その子どもの容姿に好感をもつと性格まで高く評価してしまうことなどが例として挙げられる。

(2) 対比効果

評価基準とは本来関係のない教師自身の能力や他の児童・生徒が基準となり、評価が歪むことを対比効果という。具体的には、教師が自分と比較して評価し、自分の得意分野は厳しく、苦手分野は甘く評価される現象がみられる。また、多くの人を続けて評価する際に、例えば極めて優れた(劣った)論文を評価すると、次にみる普通程度の児童・生徒への評価が不当に低く(高く)なるようなことがある。特に客観的な評価が難しい領域で生じやすいといえるが、この現象を防ぐには、本来の評価基準に立ち戻るしかないが、順序を変えて2回採点したり、複数の評価者が採点したりするなどの工夫も考えられよう。

●評価の偏り

評価者の特性により、本来の評価基準とは無関係に、すべての児童・生徒に対して実際よりも甘く、すなわち望ましい側面が強調され、短所が控えめに評価されることを**寛大化傾向(寛大効果、寛容効果)**という。逆に、実際よりも厳しく評価しがちになることを**厳格化傾向**という。また、評価軸の中心(5段階評価の3など)に評価を集中させてしまう現象は**中心化傾向**とよばれる。逆に、中心を避けて両極端な評価をしてしまうこと(5段階評価の1と5しか使わないなど)を**二極化傾向**という。これらも対比効果と同様に、本来の評価基準を明確にして再確認することが必要である。

(3) 天井効果と床効果

テスト問題が易し過ぎて、満点に得点分布が集中する現象を**天井効果**という。逆に、問題が難し過ぎて、0点またはチャンスレベルに得点分布が集中する現象を**床効果**という。チャンスレベルとは、5択の問題で正答率が20%になるなど、偶然に正答できる確率のことを指す。学習成果に個人差が想定される場面においては、天井効果も床効果も、測定道具であるテスト問題が妥当性を欠いている可能性が高い。

(4) ピグマリオン効果(教師期待効果)

ローゼンタールと**ヤコブソン**によって見出された原理である。教師が期待をもった生徒が教師の期待の方向に沿って実際に変化し得る現象を**ピグマリオン効果(教師期待効果)**という。また、この逆で、教師が先入観をもって生徒に期待せずに接することによって、生徒の成績が低下する現象を**ゴーレム効果**という。これは、教師の期待が、指導効果に大きな影響を与えるということを指摘しているが、その後の研究で、期待を抱くか、そうでないかで教師の児童・生徒に対するはたらきかけに差が生じることがわかった。すなわち、特定の児童・生徒に対して、発言の機会を多く与えたり、答えられない時でも他の児童・生徒よりも長い時間待ち続けたりヒントを与えたりするという行動が観察されるのである。これらの行動がその児童・生徒の学習成果を高める方向に作用するのであって、決して思いが通じるというような神話的な現象ではない。

教師が児童・生徒に高い期待をもてばよい結果が生じる一方で、不適切な期待は、逆に児童・生徒の学習意欲を減退させることにもつながる。このように、ピ

グマリオン効果にはプラスとマイナスの両面が含まれており、教師の期待の正確さと、それに応じた適切な指導と柔軟性が大切である。

(5) バーナム効果

誰にでも当てはまる曖昧な内容にもかかわらず、自分に当てはまるととらえてしまう現象を**バーナム効果**という。



ホーソン効果

メイヨーは、時間、賃金などの物理的要因よりも「何らかの実験に参加しており試されている」、「他のグループには負けられない」などといった意識や、インフォーマルな人間関係が生産性向上に関与していると考えた。これを**ホーソン効果**とよぶ。

5 学力の評価

(1) 学力とは

学力とは何か。これは絶対的な定義がある訳ではなく、議論の絶えない問題である。ただ、歴史的にみれば、現在では以前よりもより広く学力をとらえようという傾向にある。つまり、教科内容の知識や技能としてとらえる方法から、学習態度、興味、思考などの側面を含んだとらえ方に変わってきているのである。近年提唱されたいわゆる「新しい学力観」でも、単なる知識や技能ではなく、児童生徒の意欲や思考力、判断力、表現力などを含めた力を重視している。

また、ブルームは「認知的領域」、「情意的領域」、「精神運動的領域」の3つの領域にわたる教育目標を提示した。彼は、それらの到達度が学力との見方を示していると考えた。認知とは、知識や理解などの側面、情意とは興味、関心や価値・態度的な側面、また精神運動とは手先の技能や運動の技能の側面である。

(2) 学力の程度の示し方

学力を測定する道具として、学力テストが用いられる。上に述べた学力のすべてを、学力テストで測定できるものではない。今日の学力テストは、学力の中でも、知識などの「測りやすいところ」(認知面)を測っていると考えられる。興味、関心、態度などの幅広い学力については、観察やアンケートを用いるなどの工夫が必要である。

① 学力偏差値

標準学力テストの結果をもとに、個人の学力を客観的に示そうという試みがなされている。その代表的なものが**学力偏差値**である。学力偏差値は次の公式で求めることができる。

$$\text{学力偏差値} = \frac{\text{個人の得点} - \text{同じ年齢集団の平均値}}{\text{標準偏差}} \times 10 + 50$$

学力偏差値が50以上である場合は、平均以上の学力であることになる。

② 成就指数(AQ)

児童生徒が教育を受け、その能力に応じた学力が獲得できているかどうかの成就度を確かめるための指標を**成就指数**といい、以下の公式で求めることができる。また、**教育年齢(EA)**を**生活年齢(CA)**で割って100倍したものを**教育指数(EQ)**とよぶ。ここでの教育年齢とはその子どもの成績が何歳の子どもの成

績に相当するのかを示したものである。

$$\begin{aligned} \text{成就指数(AQ)} &= \frac{\text{学力偏差値}}{\text{知能偏差値}} \times 100 \\ &= \frac{\text{教育指数(EQ)}}{\text{知能指数(IQ)}} \times 100 \\ &= \frac{\text{教育年齢(EA)}}{\text{精神年齢(MA)}} \times 100 \end{aligned}$$

なお、知能の割に学力が劣っている子どもは、**アンダー・アチーバー**あるいは**学業不振児**とよばれ、学力が知能を上回っている子どもは**オーバー・アチーバー**とよばれる。アンダー・アチーバー、オーバー・アチーバーという視点は、子どもの学習可能性という点を踏まえて指導する際の情報として有用な場合が多い。

(3) 学力テストの作成と種類

学力テストは、筆記テストと口頭テストなどに区別ができる。歴史をさかのぼると、口頭テストが広く用いられてきた。しかし、現代においては筆記テストが主流となった。筆記テストが、共通の問題を与えられること、その場の気分や受験生の性格などに左右されにくいことなど、より公平な方法であるとみなされたためである。しかし、筆記テストでは、紙の上に示された成果からしか調べることができないなどの限界もある。ここでは、現代の教室で広く普及している筆記テストについて整理しておく。以下でいう、テストとは、筆記テストのことを意味している。

① 論文体テストと客観テスト

テストはまず、問題作成の形式によって、**論文体テスト**と**客観テスト**とに二分される。

論文体テストとは、「～について述べなさい。」といった形で記述を求める方式である。この方法には、表現能力、論理的思考力、態度などまで調べられる長所がある。また、問題作成が容易である。しかし、問題数が少なくなる、採点が主観的になる、山かけ式の学習を誘導しやすいこと、などの短所がある。そこで、論文体テスト作成に当たっては、問題数を多くすることや、「～、～、～の3つの観点から述べよ」や「～という言葉を使って述べよ」など、解答のポイントを示しておくという工夫も考えられている。

一方、客観テストとは、文字通り客観的に採点できる形式のテストであり、誰が採点しても同じ結果が得られるように解答方法が工夫されている。真偽法、完成法(穴うめ)、多肢選択法、組み合わせ法などの方法がある。

大学入試センター試験で採用されているマークシート法は、客観性を重視した形式である。コンピュータで処理されるために、採点者のきまぐれによる不公平などの問題が生じにくい。

また、客観テストには、採点が容易に、客観的にできること、出題数を多くでき信頼性を上げられること、などの長所がある。しかし一方、偶然に正答できてしまうことがある、断片的な知識の暗記学習を誘導しやすい、などの批判もなされている。

② 標準テストと教師作成テスト

テストはまた、その作り方によって、標準テストと教師作成テストとに大別できる。

標準テストとは、標準化という手続きを経ているテストのことである。標準化とは、十分な信頼性や妥当性を保証する一連の作業をいう。まず①評価の目標を明確化し、②それに沿った多数の項目を作って、③比較的少数の標本に対して予備テストを行う。ここで④適切なレベルの困難さや識別性をもつ項目を選定する。以上の手続きは反復されることもある。次に、⑤大規模な標本に対して、改めて本テストを実施する。そして、⑥本テストの結果について、信頼性や妥当性の検討がなされる。また、⑦本テストの結果に基づいて、平均点や標準偏差も算出される。このため、標準テストの受験者は偏差値を算出するなどして、自らの学力の相対的な位置を調べられる。最後に、⑧テストの実施・採点のためのマニュアルが作成される。このマニュアルには、テストの実施や採点の方法はもちろん、妥当性や信頼性のデータなども記載される。

標準化は、このようになり手間と費用のかかる手続きなので、通常は業者が教師や研究者らと協力して行っている。知能テストや性格テストなども、その多くは標準テストである。

教師作成テストとは、個々の教師が日常的に作成するテストのことで、標準化という手続きを用いない。よって、学級内部での得点比較くらいしかできない。しかし、指導する教師が問題を作成するので、診断的評価や形成的評価など、教師が知りたい情報を得るための出題内容をより適切に選べるという長所がある。

なお、業者テストという言葉は専ら、出版社や大手の学習塾が行っている模擬テストの意味で使われている。こうしたテストが、上記の標準化の手続きを経た「よいテスト」といえるのだろうか。業者テストによる偏差値は、この疑問をひきずったまま、進路指導の際の重要な判断材料としてひとり歩きしてきた感がある。

(4) テストの実施

試験監督は、受験者がその学力を十分得点に反映できるように留意しなければならない。テストの実施に当たっては、一般に次のような配慮が望まれる。

- ① 生徒に無用な圧力をかけて緊張させない。開始、終了の時刻を板書しておくなど、不安を除く配慮をする。
- ② 答案用紙配付の前に、受験上の注意の教示をすべて終えて、開始後は受験者の注意集中を乱さない。
- ③ 不正行為の防止に努める。学力テストの実施場面では通常、教師が監督者、児童生徒が受験生となる。よって、児童生徒との日頃の信頼関係の樹立は、最も基本的な予防策である。

(5) 採点の公正を期する

テストの信頼性を高めるには、採点の際に次のような配慮が求められる。

- ① どの受験者の答案かがわからないように、名前の欄を見えなくしておいてから採点する。これはいわゆるハロー効果に対する配慮である。よく授業で発言していたとか、普段の「態度がよい」、など個人に対して教師がもっている印象が、テスト結果に影響を与えてはならない。
- ② あらかじめ採点基準を設けておく。入試の場合のように受験者が多く、複数の採点者が手分けして採点に当たる場合は、特に基準が一致するように綿密な打ち合わせが不可欠である。また、論文体テストでは、いくつかの答案に目を通し、解答の類型を把握してから、採点基準を決める手もある。
- ③ 生徒の単位でなく問題の単位で、つまり1問ずつ全生徒を通して採点していく。これは、同じ答案を何問か続けて採点すると、前の問題の正誤で、後の問題の正誤を予期してしまうなど、信頼性に影響する恐れがあるためである。

6 知能テスト(知能検査)

(1) 知能とは

心理学上の知能の定義は、いろいろな角度から試みられている。ターマンは「抽象的な観念によって考える能力」だとし、ケーラーは「洞察」の能力という点を強調した。また知能テストを作ったビネーは、「思考作用であって、一定の方向を維持しようとする傾向、目標到達のための順応力、及び自己批判能力をもつもの」と考えていたようである。一方、ウェクスラーは「目的をもって行為し、合理的に考え、効果的に環境に対処する能力の総括である」と述べている。このように、学者によって様々な考え方が示されている。

これら多くの説をまとめてみると、知能を定義する視点は、次のように整理できる。

- ① 抽象的な精神的能力としての知能の見方。
- ② 環境への適応能力としての知能の見方。
- ③ 学習する能力としての知能の見方。

その他、④「知能テストにより測定された能力」との逆転の発想を提案した学者もある。

以上のように、知能の意味自体は現時点でまだ確定されていない。しかし、それを測る道具である知能テストは、急速に進歩、普及した。現在では、その意味を深くかえりみることなく、広く用いられているという状況である。一方、近年、人工知能(AI)の研究が発展した。つまり、機械であるコンピュータにも人間同様の知能のはたらきをもたせることが試みられている。

(2) 知能の構造

知能がどのような構造をしているかについては諸説あるが、ここでは中でも代表的なスピアマン、ギルフォード、サーストンの考え方を示しておく。


① スピアマンの2因子説

スピアマンは、数多くの変数の中から共通性をもった因子を取り出す手法である**因子分析**を導入した。彼は1904年に、一般因子と特殊因子の2因子で知能を説明する考え方を示した。一般因子(g因子)とはどの検査にも共通した因子であり、特殊因子(s因子)は各検査に固有の因子である。

② ギルフォードの立体モデル

ギルフォードは情報の内容(contents)、操作(operations)、所産(prod-

ucts)の3次元の組み合わせで知能を説明する立体モデルを提唱した。情報の内容とは情報の種類であって、図形的な情報、文字などの記号的信息、意味的(言語的)情報、行動的信息などから成っている。情報の操作とは情報処理の際の心的操作であって、認知、記憶、拡散的思考、集中的思考、評価から成っている。そして、所産とは、結果として出されたもので、知識の単位、単位の種類、単位間の関係、体系(組織)、変換、含蓄(内容)、から成っている(図表6-1)。



図表 6-1 ギルフォードの知能の構造

③ サーストンの多因子説

スピアマンらが一般因子の存在を主張したのに対して、**サーストン**は知能の一般因子を認めなかった。彼は、多くの検査結果を因子分析で解析した。その結果、知能は少なくとも10の独立した因子からなると考えた。そのうち主なものは、空間、知覚、数、言語、言語の流暢さ、記憶、推理の7因子である。現在用いられている知能検査にも、この7因子を参考にしたものが多い。

(3) 知能テスト(知能検査)の種類

知能テストに関し、それが作られてきた経緯や、利用上の限界をよく理解しておく必要がある。以下に、個別式と集団式に分けた上で、主な知能検査の種類とそれぞれの特徴をまとめる。

① 個別式知能検査

1) ビネー式知能テスト

個別知能検査の一つで**ビネー・シモン式知能検査**ともいう。1904年、フランスの**ビネー**と友人の医師シモンはフランス文部当局より、知的障害児を正常

児から区別するための用具の製作を依頼され、1905年、ビネー・シモン知能尺度を作成した。この検査は単なる暗記力ではなく、判断や推理力を必要とする問題状況を含んだ検査である。30問を易しいものから難しいものへと配列して段階的に作成されている。その後1908年、1911年とビネーは改訂を行い、前者では、問題を年齢級に配列し、後者では成人用を加えて内容の充実化を図った。ビネーのテストは、諸外国に広がり、改訂が繰り返された。日本では、鈴木治太郎による鈴木ビネー知能検査、田中寛一の田中ビネー知能検査などがある。

1916年、ターマンは、ビネー検査のスタンフォード改訂版（スタンフォード・ビネー・テスト）を作った。このとき精神年齢（MA）と生活年齢（CA）との比による知能指数（IQ）の表示方法が、初めて採用された。

●知能指数（IQ）

知能指数（IQ）とは、Intelligence Quotientの頭文字である。1912年にドイツのシュテルンが提唱し、ターマンがスタンフォード・ビネー・テストで導入した。精神年齢をMA、生活年齢をCA（Chronological Age：暦年齢とよぶこともある）とすると、IQは次の公式で計算できる。

$$IQ（知能指数） = \frac{MA（精神年齢）}{CA（生活年齢）} \times 100$$

公式からもわかるように、MA＝CAのとき、IQは100である。「物価指数」などにもみられるように、知能指数は比較の基準を100として表示する方法なのである。

この方法では、年齢の異なる子ども同士でも、知能程度を表現、比較できる。しかし、分母であるCAの大小によって、この比は左右される。つまり、子どもが小さいときほど極端な値を取りやすい。なお、現在では上の公式による従来のIQの算出は、必ずしも一般的ではないので、注意が必要である。

●精神年齢（Mental Age：MA）

ビネーは「各年齢群の4分の3が正答できる問題」を基準にして、しだいに困難になる問題系列を用意しておき、そのどこまでが解けるかによって精神年齢（MA）を算出した。単純に考えると、精神年齢が4歳8ヵ月という場合には、4歳8ヵ月の子どもの75%が正答できる問題をクリアしたということ意味する。

2) ウェクスラー式知能検査

ウェクスラーは、ニューヨークの病院で長く臨床に携わっており、独自の視点からウェクスラー・ベルヴュー知能検査を開発した。この検査は、10歳から60歳までを適用年齢とし、6種類の言語性検査と5種類の動作性検査によって構成された個別式の知能検査である。

後にこれを改定し、成人用としてWAIS（Wechsler Adult Intelligence Scale、ウェイスと発音）、児童用としてWISC（Wechsler Intelligence Scale for Children、ウィスクと発音）、幼児用としてWPPSI（Wechsler Pre-school and Primary Scale of Intelligence、ウィブシと発音）が作成され、改訂を重ねている（現在用いられているものは、いずれも改訂版であり日本版として標準化されたもので、第四版を表すIVや、第五版を表すVなどを付けてよぶ）。これらの知能検査を総称して、ウェクスラー式知能検査とよぶ。

最新版のWISC-Vでは、16の下位検査（10の主要下位検査と6の二次下位検査）から、全体的な知能を表す全検査IQと、特定の領域の知能を表す5つの主要指標得点（言語理解・視空間・流動性推理・ワーキングメモリー・処理速度）、付加的な情報としての5つの補助指標得点（量的推理・聴覚ワーキングメモリー・非言語性能力・一般知的能力・認知熟達度）が算出される。

●偏差知能指数（DIQ）

ある個人の属する年齢集団内での相対的位置を表すことができ、なおかつ、IQと同様に平均が100となるようにした数値を偏差知能指数という。ウェクスラー式知能検査や2024年8月に改訂された田中ビネー知能検査VIではこの数値が用いられている。偏差知能指数の算出には、偏差値の式を修正した次の公式を用いる。

$$DIQ = \frac{15(X-M)}{SD} + 100$$

X：個人の得点

M：その年齢集団の平均点

SD：その年齢集団の標準偏差

3) その他の個別式知能検査

グッドイナフは、児童の知能を測定する検査として描画の手法を導入し、人物画知能テスト（DAM；Draw-a-Man Test）を考案した。この検査では、身近な人間の絵を指定しないで自由に描かせ、その描かれた人物の構造から知能の発達水準を診断、評価する。

イリノイ大学のカークらは、**学習障害 (LD)**の診断において他の知能検査と併用できる**ITPA** (Illinois Test of Psycholinguistic Abilities)を開発した。この検査は、**言語学習能力診断検査**であり、子どもの言語能力を情報処理過程のモデルに基づいて分析し、それらの処理過程のどの部分に欠陥があるのかわかるように工夫されている。

また、**カウフマン**夫妻は、認知処理過程と知識・技能の習得度の両方面から子どもの知能を測定・診断する**K-ABC心理・教育アセスメントバッテリー** (Kaufman Assessment Battery for Children)を開発している。我が国では1993年に標準化され、障害児教育の領域をはじめとして広がりを見せている。

② 集団式知能検査

アメリカ合衆国は、1917年に第一次世界大戦に参戦した。これに伴い、前線に送り出す兵士を、その能力に応じて配置する必要が主張された。そこで、大規模な団体式の知能テストが必要となった。それまでの知能テストは検査者と被検査者が1対1で行う個別式検査であった。しかも、新兵には英語を話せない移民も多数いた。ここに作業検査、集団式検査を開発する必要が生じ、ヤーキーズによって軍隊検査 (U. S. Army Test) が創案された。軍隊検査には、英語による α 式と、図形、記号、数字だけを用いる β 式とがあった。このように、専ら言語に頼るテストと頼らないテストとを用いる考え方は、現在の団体式知能テストにも引き継がれている。

しかし、こうした当時の集団での知能テストの実施には、問題点も多かった。それは主に限られた時間で、多数の人に同時に実施するため、指示の不徹底、時間不足、調査者の訓練の不十分さなどが生じることであった。現在では、テストといえば教室、鉛筆と紙、時間制限、などという状況を直ちに思い浮かべられるが、軍隊検査の行われた時代背景を考えると、こうした前提はまだ成り立っていなかったのである。

例えば、**ゲールド**によると、 α 式では「ワシントン対アダムズ (第2代大統領) は第1対第〜である」という項目があった。これは明らかに移民が不利になる項目の例といえる。このようなテスト項目で、「生得的な知能」が測れるとは思えない。また言語に依存しないといわれた β 式にしても、当時の社会状況で、それまで鉛筆をまともに持ったことさえなかった人を対象として妥当であったかどうか、おおいに疑問である (ゲールド、鈴木・森脇訳1989『人間の測りまちがい—差別の科学史』河出書房新社)。

α 式は今日の**A式**、 β 式は今日の**B式**へと名前が受け継がれていく。学校現場でよく用いられる「田中B式」のBは、 β から派生したものである。現在用いら

れている知能テストは、A式とB式との併用 (AB式検査、AB併用検査などという)が多い。

(4) 知能の発達

年齢とともに個人の知能は変化するか否かという議論があった。知能は変わらないとする知能の恒常性を唱える説もみられたが、実際には変化する事例もたくさんあり、単純に特定の時点での知能をもってその人の将来の知能を予測することは不適当である。教師が1回の知能テストの結果だけで子どもの知能を決めつけることはできないのである。

知能は幼児期から青年期にかけて急激に増加し、20歳頃にピークを迎えるというデータがある。ただしこれは知能検査の得点の推移に基づいているものであり、幅広い知的能力の中には、年齢とともにさらに後まで伸びていく領域もある。例えば、新しい事態に対処していく際に必要な**流動性知能** (流動性一般能力) は確かに成人期以降は徐々に低下するかもしれないが、過去の学習経験をもとにした判断を行う際に発揮される**結晶性知能** (結晶性一般能力) は成人期以降も上昇を続け、老年期に至っても衰えにくいといわれている。

(5) 結果の解釈と利用

既に述べたとおり、知能には様々な種類がある。解釈に当たっては、誤解のないようにしなければならない。

知能テストには、教育可能性を予測する、つまり特別な能力をもっている子、精神的な遅滞のある子、などを予め知り、能力に応じて適切な教育をするという利用方法がある。ただ、知能テストは、現状では広く普及しているが、出てきた数値がうまく活用されていない。むしろ、濫用、誤用の危険性を指摘する声も高い。

IQは単純なので、直感的にわかりやすいし、比較しやすい。しかし、明らかに次のような限界がある。

- ① 唯一絶対的な数字ではない。テストの種類により、その理論的な基礎や、結果の表示方法も異なる。結果もかなり幅をもって読む必要がある。IQは、他の心理学的な概念と同様に、間接的に測定される。体重や身長などのような物理的、直接的な測定とは異なる上、誤差が大きい。
- ② 知能そのものの定義がまだ定まっていない以上、知能テストの結果が直ちに知能を測定したものとはいえない。むしろ、知能の理論の流れからいえば、現在の知能テストで測定されている能力は、非常に限定的なものでしかない。
- ③ 知能テストに備えての練習は、効果はあるが意味はない。むしろ専門家の判

断を誤らせる危険さを含む。なお、練習の結果により簡単に得点が上がる事実が、逆に現在の知能テストの限界を暗示している。

- ④ 現在の心理テストは、知能テストが誕生した当初と比較すればはるかに進歩している。しかし、残念なことに、こうした心理的な測定のもつ限界は現在でも広く認識されてはおらず、拡大解釈や誤用は後を絶たない。知能テストについてはその限界を知り、一つの道具として活用する気持が必要である。

tea time



創造性と知能、学力

創造性の発揮には基礎的知識が必要なため、知能がある程度高いことが要求される。しかし、IQ120以上の者同士で比べると、知能と創造性は性格の異なる知的能力であることがわかっている。

創造性の高い人は学習に積極的であり、好奇心も強い。そういった特性が働いて、創造性の高い人は学力も高くなる可能性をもつ。このことを実証した研究としてはゲッウエルスとジャクソンによるものが有名である。

7 教育統計

(1) 標準偏差

ここではまず、標準偏差 (Standard Deviation : SD) について解説しておく。

平均値とは、ある得点分布の中央がどのあたりかを教えてくれる数値である。これに対して、標準偏差は分布の散らばりの程度を示す数値である。つまり、平均値の近くに多くの人が分布しているのか、もっと幅広い範囲にわたって分布しているのかを、標準偏差は示してくれる。

標準偏差は、個人のテスト得点と、平均値との差の概要を知るために考案されたものである。そこで、まず $X - M$ (偏差 = d) を2乗して足す (偏差を2乗するのは、偏差をそのまま足すと、必ずゼロになってしまう役に立たないからである)。次に人数で割って偏差の2乗の平均を出す (これが「分散」とよばれる数字になる)。最初に偏差を2乗してから足しているの、最後に分散を開平方しておくのである。

平均の前後1 SDの範囲内に、生徒のうち約3分の2が入る。

$$SD = \sqrt{\frac{\sum (X - M)^2}{N}}$$

ただし

X : 個人のテスト得点

M : その年齢集団の平均点

N : 受験者数

図表6-2に、受験者5名 ($N=5$) のテストにおける標準偏差の算出例を示す。

ただし X は個人のテスト得点。 M はその年齢集団の得点の平均値。 Σ は総計をとる。 d は偏差 ($X - M$)。

$$\text{平均点は, } \frac{\sum X}{N} = \frac{120}{5} = 24$$

$$\text{標準偏差は, } \sqrt{\frac{370}{5}} = \sqrt{74} \approx 8.6 \text{ となる。}$$

ここでは、わかりやすいように5名だけの結果を例示したが、実際にはこのような少ない受験者の場合には、平均や標準偏差を求めてもあまり意

氏名	X	M	d	d^2
東京勇太	10	24	-14	196
横浜理恵	20	24	-4	16
・	25	24	1	1
・	30	24	6	36
・	35	24	11	121
合計	120		0	370

$$\Sigma d^2 = 370$$

図表6-2 標準偏差の算出例

味がない。5人くらいであれば、全員の得点を羅列してもよいからである。受験者数が非常に多く、他の人との比較が難しいようなときにこそ、平均や標準偏差が威力を発揮する。

(2) 偏差値

偏差値とは平均が50、標準偏差が10になるように数学的に変換した値のことである。標準偏差 (SD) が求められたら、次の式に従い、個人の偏差値 (SS) が算出できる。 X は個人のテスト得点、 M は平均点である。

$$SS = \frac{10(X-M)}{SD} + 50$$

例えば得点が30点の人の場合、偏差値は次のようになる。

$$SS = \frac{10(30-24)}{8.6} + 50 \\ \approx 57$$

なお、知能についての偏差値を求めれば知能偏差値とよばれ、学業成績についての偏差値は学力偏差値とよばれる。いずれにしても計算式は共通であり、成績指数などを算出する際に用いられることがある。

(3) 正規分布

テスト結果のようなデータは縦軸に人数、横軸に得点を取ったヒストグラムを描くと、その特徴が理解しやすい。得られたデータのヒストグラムを描いたときにみられる左右対称の釣り鐘型の分布を**正規分布**という。一般にデータ数が多くなればなるほど、その分布は正規分布に近づくといわれている。

(4) t検定

仮にA、Bという2つの教え方があって、どちらが優れているのかを実験的に検討する場合を考えてみよう。通常、学力がほぼ同等な実験群Aと実験群Bまたは統制群をつくって、平均点を比較する方法がとられるだろう。一定期間別々の方法で教えた後、学力テストを実施して得点を比較する。さて、指導後の平均点を比べて、高い方がよい教え方だといえるだろうか。

実は、こうした実験では、平均値だけを比較して結論を導くことはできないのである。一見、AとBとでAの方が平均値が少しでも高ければ、Aの方がよいと思いがちだが、例えば両群の差が1点だったらどうだろうか。単なる誤差の範囲内で

はないのだろうか。

こうした場合にすべきことは、統計的な仮説検定である。世論調査などと同じように、心理学の実験では限られた数の標本を調べる。中学校1、2年生100名を対象とした実験とか、高等学校の2クラスを用いた実験などのように、限られた人たちが参加する。そして、中学生全般のような「母集団」について、例えば「A、Bどちらの方法が一般的に優れているのか」という結論を引き出すことをねらうのである。

この際、まず**帰無仮説**とよばれる「AとBとに差は無い」という形の仮説を立てる。そして、標本を調べた結果次第で、帰無仮説を「捨てる」べきか「受け入れる」べきかを推測し、決定する。これが、統計的な仮説検定である。

このように、母集団についての推定をするようなときには、一定の手順がある。**t検定**は、統計的な仮説検定で用いられる代表的な方法の一つである。**t検定**は、2つの母集団について差があるか否かを調べる検定である。

なお、**F検定**とは、3つ以上の母集団を調べるときに用い、母集団の分散が等しいかどうかを検定するものである。

教師が自身の実践を確かなものにしようとするとき、時に科学的に実践を振り返ることが必要になる。統計的手法は指導改善に無縁のものではなく、むしろもっと根付いていなくてはならないものといえよう。

確認問題

229
教育心理

21 次の文の()に適語を入れよ。

知能検査は、フランスの(A)が20世紀の初めに開発したものが基礎となっている。その後、アメリカの(B)によって改良されたものがスタンフォード・ビネー・テストで、初めて知能指数(IQ)が導入された。知能指数は、(C)を生活年齢で割って、その値に100をかけて算出される。

一方、同じく個別式の知能検査でありながら、異なる特徴をもつものがある。(D)式知能検査では、対象者の年齢によって成人用の(E)、児童用の(F)、幼児用のWPPSIの3つが用意されている。

22 次の文の()に適語を入れよ。

- 前もって評価点ごとの人数を決めることなく、到達すべき目標を決めて行う評価が(絶対評価)である。(→到達度評価)
- 学習活動の始めに行い、学習者がどの程度のレディネスを備えているかを評価するものを()という。(→診断的評価)
- 学習活動の途中に行い、指導計画の修正や補充的指導に活用するための評価を()という。(→形式的評価)

23 次の説明に最も近い語句を語群より選べ。

- 他人について認知するとき、あるよい面を知っていると、それが影響して、結果として歪んだ評価をもたらすことがある。(→ウ:ハロー効果)
- 評価者である教師が特定の児童・生徒に何らかの期待をもつと、実際のはたらきかけが変わって、結果として期待した方向に児童・生徒が変化することがある。(→イ:ピグマリオン効果)
- テスト問題が易しすぎて満点に得点分布が集中し、学習成果の個人差を反映した適正な評価が困難になることがある。(→オ:天井効果)
- 評価基準となるべき教育目標ではなく、評価者自身や他の評価対象が基準になってしまい、特定の評価者への評価が不当に高くなったり低くなったりすることがある。(→エ:対比効果)

230
教育心理

【語群】

- ア. ホーソン効果 イ. ピグマリオン効果 ウ. ハロー効果
エ. 対比効果 オ. 天井効果